

STATISTIKA DAN PROBABILITAS

“Laporan Audit Statistik Repository Pandas-Dev/Pandas”

Dosen Pengampu: Muhammad Ridho Kurniawan Pratama, S.Kom., M.T.I.



Intelligentia - Dignitas

Disusun Oleh:

Ahmad Aqil Fadria	1519625006
Nasya Putri Salsabila	1519625007
Muhammad Hanief Inayaturn Rahman	1519625026
Muhammad Rizqi Hazami	1519625064
Krishna Dhikha Pratama	1519625070

**SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS NEGERI JAKARTA
2026**

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Allah SWT atas rahmat dan karunia-Nya sehingga laporan berjudul “Laporan Audit Statistik Repository Pandas-Dev/Pandas” dapat diselesaikan dengan baik. Laporan ini disusun sebagai tugas akhir kelompok mata kuliah Statistika dan Probabilitas, Program Studi Sistem dan Teknologi Informasi, Fakultas Teknik, Universitas Negeri Jakarta.

Laporan ini menyajikan hasil audit statistik terhadap repository open-source pandas-dev/pandas menggunakan metode-metode statistik yang telah dipelajari selama perkuliahan, meliputi estimasi parameter, interval kepercayaan, pengujian hipotesis, dan simulasi probabilistik. Data dikumpulkan melalui GitHub REST API dan dianalisis menggunakan Python.

Kami mengucapkan terima kasih yang sebesar-besarnya kepada Bapak Muhammad Ridho Kurniawan Pratama, S.Kom., M.T.I. selaku dosen pengampu mata kuliah Statistika dan Probabilitas yang telah memberikan bimbingan, arahan, dan ilmu yang sangat bermanfaat. Ucapan terima kasih juga kami sampaikan kepada seluruh anggota kelompok yang telah bekerja keras dan bekerja sama dalam menyelesaikan laporan ini.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kami sangat mengharapkan kritik dan saran yang membangun dari pembaca demi perbaikan laporan di masa mendatang. Semoga laporan ini dapat memberikan manfaat bagi pembaca dan berkontribusi pada pengembangan ilmu statistika terapan.

Jakarta, 09 Juni 2026

Kelompok 6

DAFTAR ISI

KATA PENGANTAR	2
DAFTAR ISI	3
BAB I <u>P</u> ENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Manfaat Penelitian.....	5
BAB II <u>T</u> INJAUAN PUSTAKA	6
2.1 Distribusi Bernoulli dan MLE	6
2.2 Distribusi Poisson dan MLE	6
2.3 Interval Kepercayaan.....	6
2.4 Pengujian Hipotesis Non-Parametrik	7
2.5 Bloom Filter	7
BAB III <u>M</u> ETODOLOGI	8
3.1 Sumber Data.....	8
3.2 Proses Pengumpulan Data	8
3.3 Metode Analisis	8
BAB IV <u>H</u> ASIL DAN PEMBAHASAN	10
4.1 Eksplorasi Data (EDA).....	10
4.2 Estimasi Parameter	10
4.3 Interval Kepercayaan.....	12
4.4 Pengujian Hipotesis.....	12
4.5 Analisis Komputasional (Bloom Filter)	14
BAB V <u>P</u> ENUTUP	15
5.1 Kesimpulan	15
5.2 Saran.....	16

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi perangkat lunak open-source telah menciptakan ekosistem kolaborasi global yang luar biasa. Repository GitHub menjadi pusat aktivitas pengembangan, di mana ribuan kontributor dari seluruh dunia berinteraksi melalui mekanisme issues dan pull requests. Di antara sekian banyak repository open-source, `pandas-dev/pandas` merupakan salah satu yang paling signifikan dalam ekosistem Python, digunakan oleh jutaan data scientist, analis, dan pengembang perangkat lunak di seluruh dunia.

Library `pandas` menyediakan struktur data dan alat analisis data yang fleksibel dan ekspresif untuk Python, menjadi fondasi penting dalam pemrosesan data di berbagai domain mulai dari keuangan, ilmu pengetahuan, hingga kecerdasan buatan. Mengingat peran krusialnya, kesehatan repository `pandas-dev/pandas` menjadi hal yang sangat penting untuk dipantau dan dievaluasi secara berkala.

Audit statistik terhadap repository open-source merupakan pendekatan ilmiah untuk mengukur dan mengevaluasi kualitas proses pengembangan perangkat lunak. Dengan menerapkan metode-metode statistik seperti estimasi parameter Maximum Likelihood Estimation (MLE), konstruksi interval kepercayaan, pengujian hipotesis, dan simulasi probabilitas, kita dapat memperoleh gambaran kuantitatif yang objektif tentang dinamika kontribusi, tingkat penerimaan perubahan, efisiensi penyelesaian masalah, dan tren perkembangan repository dari waktu ke waktu.

Penelitian ini menganalisis 4.389 closed issues dan 5.000 pull requests dari repository `pandas-dev/pandas` yang dikumpulkan melalui GitHub REST API. Lima anggota tim bekerja secara paralel dengan pembagian peran yang jelas: Data Engineer, Estimation Analyst, Inference Analyst, Hypothesis Analyst, dan Computation Analyst, masing-masing berkontribusi pada satu lapisan analisis statistik.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Berapa probabilitas estimasi sebuah pull request di-merge di repository `pandas-dev/pandas`?

2. Berapa rata-rata jumlah komentar per issue di repository pandas-dev/pandas?
3. Apakah terdapat perbedaan yang signifikan dalam durasi penyelesaian issue antara tahun 2025 dan tahun 2026?
4. Bagaimana efektivitas Bloom Filter sebagai struktur data probabilistik dalam konteks audit repository?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengestimasi parameter probabilitas merge rate pull request dan rata-rata komentar per issue menggunakan metode Maximum Likelihood Estimation (MLE).
2. Mengkonstruksi interval kepercayaan 95% untuk parameter yang diestimasi menggunakan metode Wald, Wilson, dan Bayesian.
3. Menguji hipotesis tentang perbedaan durasi penyelesaian issue antara tahun 2025 dan 2026 menggunakan uji statistik yang sesuai.
4. Mengimplementasikan dan menganalisis Bloom Filter sebagai representasi simulasi probabilistik dalam konteks repository audit.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi Akademisi: Memberikan contoh penerapan nyata metode-metode statistik pada data engineering dan open-source software analysis.
2. Bagi Maintainer pandas: Menyediakan data kuantitatif berbasis statistik yang dapat digunakan sebagai dasar pengambilan keputusan dalam mengelola kontribusi.
3. Bagi Kontributor: Memberikan gambaran tentang peluang penerimaan kontribusi dan karakteristik proses review di pandas-dev/pandas.

BAB II

TINJAUAN PUSTAKA

2.1 Distribusi Bernoulli dan MLE

Distribusi Bernoulli adalah distribusi probabilitas diskrit yang memodelkan percobaan dengan dua kemungkinan hasil: sukses ($X = 1$) dengan probabilitas θ , dan gagal ($X = 0$) dengan probabilitas $1-\theta$. Fungsi massa probabilitasnya adalah $P(X = x) = \theta^x(1-\theta)^{1-x}$, di mana $x \in \{0,1\}$.

Maximum Likelihood Estimation (MLE) adalah metode statistik untuk mengestimasi parameter populasi dengan memaksimalkan fungsi likelihood — probabilitas mengamati data yang ada, diberikan nilai parameter tertentu. Untuk distribusi Bernoulli dengan n observasi dan k sukses, derivasi MLE menghasilkan estimator $\hat{\theta} = k/n$, yaitu proporsi sampel (Casella & Berger, 2002).

2.2 Distribusi Poisson dan MLE

Distribusi Poisson memodelkan jumlah kejadian dalam interval waktu atau ruang tertentu, dengan parameter λ yang merepresentasikan rata-rata kejadian. Distribusi ini cocok untuk count data seperti jumlah komentar per issue yang bersifat diskrit dan non-negatif. MLE untuk distribusi Poisson menghasilkan estimator $\hat{\lambda} = \sum x_i/n = \bar{x}$, yaitu rata-rata sampel.

Analisis Bayesian menggunakan distribusi Beta sebagai prior konjugat untuk Bernoulli. Dengan prior Beta(1,1) yang uninformative, posterior setelah mengamati k sukses dan m gagal adalah Beta(α, β) di mana $\alpha = k+1$ dan $\beta = m+1$.

2.3 Interval Kepercayaan

Interval kepercayaan (confidence interval) adalah rentang nilai yang, dengan prosedur berulang, akan mencakup parameter populasi sesungguhnya dengan frekuensi yang ditentukan (misalnya 95%). Terdapat beberapa metode konstruksi CI untuk proporsi:

- Wald CI: Menggunakan aproksimasi normal, $\hat{\theta} \pm z_{\alpha/2} \times SE(\hat{\theta})$. Sederhana namun kurang akurat untuk θ mendekati 0 atau 1.
- Wilson CI: Lebih robust dan direkomendasikan untuk proporsi, terutama saat n kecil atau θ mendekati batas.
- Credible Interval (Bayesian): Berbeda secara fundamental — menyatakan probabilitas langsung bahwa parameter berada dalam interval, bukan pernyataan prosedural.

2.4 Pengujian Hipotesis Non-Parametrik

Mann-Whitney U test adalah uji non-parametrik yang membandingkan distribusi dua sampel independen tanpa asumsi normalitas. Uji ini lebih robust dibanding uji-t ketika asumsi normalitas tidak terpenuhi. Uji ini menguji apakah nilai-nilai dari satu populasi cenderung lebih besar dari populasi lain.

Effect size Cohen's d mengukur besar perbedaan praktis antara dua kelompok, di mana nilai 0.2 tergolong kecil, 0.5 sedang, dan 0.8 besar (Cohen, 1988). Effect size melengkapi p-value dengan informasi tentang signifikansi praktis.

2.5 Bloom Filter

Bloom Filter adalah struktur data probabilistik yang didesain oleh Burton Howard Bloom pada 1970 untuk pengujian keanggotaan elemen secara efisien. Menggunakan array bit dan beberapa fungsi hash, Bloom Filter dapat menentukan apakah elemen ada dalam himpunan dengan kompleksitas waktu $O(k)$ konstan, di mana k adalah jumlah fungsi hash.

Trade-off utama Bloom Filter adalah kemungkinan false positive — menyatakan elemen ada padahal tidak. False Positive Rate (FPR) teoretis dihitung sebagai $(1 - e^{(-kn/m)})^k$, di mana n adalah jumlah elemen, m adalah ukuran bit array, dan k adalah jumlah fungsi hash. Tidak ada false negative — jika Bloom Filter menyatakan elemen tidak ada, maka benar-benar tidak ada.

BAB III METODOLOGI

3.1 Sumber Data

Data dalam penelitian ini bersumber dari GitHub REST API v3, mengakses repository publik `pandas-dev/pandas`. Repository ini dipilih karena merupakan salah satu proyek open-source Python paling aktif dan signifikan, sehingga memberikan dataset yang kaya dan representatif untuk analisis statistik.

Item	Detail
Repository	<code>pandas-dev/pandas</code>
Source URL	https://api.github.com/repos/pandas-dev/pandas
Metode Pengumpulan	GitHub REST API v3 (token-authenticated)
Rentang Waktu	2023–2026
Tanggal Pengambilan	Mei 2026
Total Issues (setelah cleaning)	4.389 records
Total PR (setelah cleaning)	5.000 records

3.2 Proses Pengumpulan Data

Pengumpulan data dilakukan secara bertahap menggunakan GitHub REST API dengan pagination untuk mengatasi batas rate limit. Data mentah berupa JSON dikonversi ke format CSV. Proses cleaning mencakup:

- Filtering hanya issues dengan status closed (karena durasi penyelesaian hanya dapat dihitung untuk issues yang sudah ditutup).
- Pemilihan kolom yang relevan: `id`, `number`, `title`, `state`, `created_at`, `closed_at`, `comments`.
- Feature engineering: menghitung `close_duration_days` dari selisih `closed_at` dan `created_at`, serta membuat kolom `is_closed`.
- Untuk PR dataset: menghitung `review_duration_days` dan mengekstrak kolom `merged` sebagai variabel biner.

3.3 Metode Analisis

Analisis dilakukan dalam lima lapisan yang saling berkaitan:

Lapisan	Notebook	Metode	Role
EDA	<code>01_ed.ipynb</code>	Statistik deskriptif, visualisasi	Data Engineer

Lapisan	Notebook	Metode	Role
		distribusi dan tren	
Estimasi Parameter	02_estimation.ipynb	MLE Bernoulli, MLE Poisson, Beta Posterior	Estimation Analyst
Interval Kepercayaan	03_inference.ipynb	Wald CI, Wilson CI, Credible Interval	Inference Analyst
Pengujian Hipotesis	04_hypothesis_testing.ipynb	Shapiro-Wilk, Levene, Mann-Whitney U, Welch t-test	Hypothesis Analyst
Simulasi	05_simulation.ipynb	Bloom Filter, analisis FPR	Computation Analyst

Seluruh analisis dilakukan menggunakan Python 3.11 dengan library numpy, pandas, scipy, matplotlib, dan seaborn. Kode diorganisasi dalam Jupyter notebooks dan modul Python yang dapat direproduksi.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data (EDA)

Eksplorasi data awal dilakukan untuk memahami karakteristik dataset sebelum analisis statistik yang lebih mendalam. Beberapa temuan utama dari EDA adalah sebagai berikut.

Distribusi durasi penyelesaian issue (`close_duration_days`) menunjukkan pola yang sangat right-skewed, di mana sebagian besar issue diselesaikan dalam waktu singkat (0–30 hari) namun terdapat outlier yang memerlukan ratusan hingga ribuan hari. Hal ini mengindikasikan bimodal pattern, ada issues yang mudah diselesaikan dan ada yang memerlukan diskusi panjang.

Statistik	Issues (<code>close_duration_days</code>)	PR (<code>review_duration_days</code>)
Count	4.389	5.000
Mean	Bervariasi per tahun	Bervariasi per tahun
Median	Lebih rendah dari mean	Lebih rendah dari mean
Distribusi	Right-skewed	Right-skewed

Tren bulanan menunjukkan aktivitas kontribusi yang konsisten sepanjang 2023–2026, dengan peningkatan bertahap dalam jumlah issues dan PR yang diselesaikan. Hal ini mencerminkan pertumbuhan ekosistem kontributor yang sehat.

4.2 Estimasi Parameter

Estimasi parameter dilakukan menggunakan metode Maximum Likelihood Estimation (MLE) untuk dua variabel utama.

A. MLE Bernoulli - Tingkat Merge Pull Request

Setiap PR dimodelkan sebagai percobaan Bernoulli independen. Derivasi MLE dilakukan sebagai berikut:

$$\text{Fungsi likelihood: } L(\theta) = \theta^k \times (1 - \theta)^{n-k}$$

$$\text{Log-likelihood: } \ln L(\theta) = k \cdot \ln \theta + (n - k) \cdot \ln(1 - \theta)$$

$$\text{Turunan dan solusi: } d \ln L / d\theta = k/\theta - (n - k) / (1 - \theta) = 0 \Rightarrow \theta = k/n$$

Parameter	Nilai
k (PR di-merge)	3.293
n (total PR)	5.000
θ (MLE)	0,6586
SE(θ)	0,0067

Interpretasi: Dengan $\theta = 0,6586$, sekitar 65,86% pull request di repository pandas-dev/pandas berhasil di-merge. Nilai SE = 0,0067 yang sangat kecil mengkonfirmasi presisi estimasi yang tinggi akibat ukuran sampel yang besar ($n = 5.000$). Hasil ini menunjukkan bahwa mayoritas PR diterima, mencerminkan komunitas kontribusi yang produktif dan proses review yang selektif namun terbuka.

B. MLE Poisson - Rata-rata Komentar per Issue

Jumlah komentar per issue adalah count data yang sesuai dimodelkan dengan distribusi Poisson. Derivasi MLE menghasilkan $\hat{\lambda} = \sum x_i / n = \bar{x}$.

Parameter	Nilai
n (jumlah issues)	4.389
$\hat{\lambda}$ (MLE)	2,3841
SE(λ)	0,0233

Interpretasi: Rata-rata 2,38 komentar per issue mengindikasikan diskusi yang efisien dan tidak bertele-tele. Maintainer merespons dengan cepat dan langsung menuju penyelesaian, mencerminkan komunitas yang matang. SE = 0,0233 menunjukkan estimasi yang sangat presisi.

C. Beta Posterior - Analisis Bayesian

Dengan menggunakan prior Beta (1,1) yang uninformative (seragam), posterior diperbarui berdasarkan data observasi. Posterior yang dihasilkan adalah Beta (3294, 1708) dengan karakteristik:

- Posterior Mode: 0,6586 (identik dengan MLE karena prior seragam)
- Posterior Mean: 0,6585
- 95% Credible Interval: [0,6453; 0,6716]

Perbedaan mendasar antara credible interval Bayesian dan confidence interval frequentist adalah interpretasinya: credible interval menyatakan secara langsung bahwa ada probabilitas 95% parameter θ berada dalam rentang tersebut, sedangkan confidence interval adalah pernyataan prosedural tentang reliabilitas metode estimasi.

4.3 Interval Kepercayaan

Tiga metode konstruksi confidence interval 95% diterapkan untuk parameter θ (merge rate) dan λ (komentar per issue).

Metode	Batas Bawah	Batas Atas	Lebar
Wald CI	0,6455	0,6717	0,0262
Wilson CI	0,6453	0,6716	0,0263
Bayesian Credible Interval	0,6453	0,6716	0,0263
Normal Approx CI (λ)	2,3385	2,4298	0,0913

Interpretasi frequentist yang benar: Confidence interval 95% Wald [0,6455; 0,6717] berarti jika prosedur konstruksi interval ini diulang sebanyak 100 kali pada sampel berbeda dari populasi yang sama, maka rata-rata 95 dari 100 interval tersebut akan mencakup nilai θ yang sesungguhnya. Pernyataan ini adalah tentang reliabilitas prosedur jangka panjang, bukan tentang probabilitas suatu interval tertentu mengandung θ .

Konsistensi ketiga metode (Wald, Wilson, Bayesian) yang menghasilkan interval hampir identik merupakan bukti robustness estimasi. Lebar interval yang sempit ($\approx 0,026$) mencerminkan presisi tinggi dari ukuran sampel yang besar.

4.4 Pengujian Hipotesis

Pengujian hipotesis dilakukan dengan prosedur enam langkah untuk menjawab pertanyaan: apakah terdapat perbedaan signifikan dalam durasi penyelesaian issue antara tahun 2025 dan 2026?

Langkah 1 - Pernyataan Hipotesis:

H_0 : Distribusi `close_duration_days` tahun 2025 = distribusi tahun 2026 (tidak ada perbedaan)

H_1 : Distribusi `close_duration_days` tahun 2025 $\neq$ distribusi tahun 2026 (ada perbedaan) - uji dua arah

Langkah 2 - Tingkat Signifikansi:

$\alpha = 0,05$ (tingkat signifikansi 5%)

Langkah 3 - Pengecekan Asumsi:

Uji	Statistik	p-value	Keputusan
Shapiro-Wilk (2025)	$W = 0,5331$	$p = 2,69 \times 10^{-34}$	Tolak $H_0 \rightarrow$ Tidak normal
Shapiro-Wilk (2026)	$W = 0,5353$	$p = 3,08 \times 10^{-34}$	Tolak $H_0 \rightarrow$ Tidak normal
Levene's Test	$W = 170,70$	$p = 2,68 \times 10^{-38}$	Varians tidak homogen

Karena kedua asumsi (normalitas dan homogenitas varians) tidak terpenuhi, uji parametrik t-test standar tidak tepat digunakan. Uji non-parametrik Mann-Whitney U dipilih sebagai uji utama.

Langkah 4 - Perhitungan Statistik Uji:

Uji	Statistik	p-value
Mann-Whitney U (utama)	$U = 2.763.969,50$	$p = 4,03 \times 10^{-26}$
Welch's t-test (konfirmasi)	$t = 14,9670$	$p = 5,80 \times 10^{-49}$
Cohen's d (effect size)	$d = 0,4257$	Kecil (small)

Langkah 5 - Keputusan Statistik:

p-value Mann-Whitney U $= 4,03 \times 10^{-26} < \alpha = 0,05 \rightarrow$ TOLAK H_0

p-value Welch's t-test $= 5,80 \times 10^{-49} < \alpha = 0,05 \rightarrow$ TOLAK H_0 (konsisten)

Langkah 6 - Interpretasi dan Effect Size:

Terdapat perbedaan yang signifikan secara statistik antara durasi penyelesaian issue tahun 2025 dan 2026. Issues pada tahun 2026 diselesaikan rata-rata 19,3 hari lebih cepat dibandingkan tahun 2025. Namun, nilai Cohen's $d = 0,4257$ menunjukkan effect size yang tergolong kecil, artinya meskipun perbedaan nyata secara statistik, signifikansi praktisnya bersifat moderat.

Perbaikan dalam kecepatan penyelesaian issue kemungkinan disebabkan oleh kombinasi faktor: peningkatan kapasitas tim maintainer, perbaikan proses triaging dan labeling, serta maturitas ekosistem kontributor yang semakin baik dalam mengikuti panduan kontribusi.

4.5 Analisis Komputasional (Bloom Filter)

Bloom Filter diimplementasikan untuk memodelkan pengujian keanggotaan issue ID secara probabilistik dalam konteks repository audit.

Justifikasi pemilihan Bloom Filter: Pertama, efisiensi memori, Bloom Filter menggunakan memori jauh lebih kecil dibanding hash set untuk dataset besar. Kedua, kecepatan lookup $O(k)$ konstan terlepas dari ukuran dataset. Ketiga, memiliki FPR yang dapat dihitung secara teoretis sehingga cocok untuk analisis statistik. Keempat, relevan secara aplikatif untuk deteksi duplikasi issue dalam repository aktif.

Metrik	Nilai
FPR Teoretis	$4,19 \times 10^{-6}$
FPR Empiris	0,0065 (0,65%)
Selisih	FPR empiris $\sim 1.550\times$ lebih tinggi dari teoritis

FPR empiris (0,65%) lebih tinggi dari nilai teoretis ($4,19 \times 10^{-6}$) karena parameter implementasi (ukuran bit array dan jumlah fungsi hash) belum dioptimalkan secara penuh. Perbedaan ini adalah trade-off yang expected dan dapat dikurangi dengan memperbesar ukuran bit array atau menambah jumlah fungsi hash, dengan konsekuensi peningkatan penggunaan memori.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan audit statistik yang telah dilakukan terhadap repository pandas-dev/pandas, dapat ditarik kesimpulan sebagai berikut:

1. Estimasi MLE menghasilkan tingkat merge pull request $\theta = 0,6586$ (65,86%) dengan $SE = 0,0067$. Ini berarti lebih dari dua pertiga PR yang diajukan berhasil diterima oleh maintainer, mencerminkan proses review yang produktif dan selektif. Rata-rata komentar per issue $\lambda = 2,3841$ menunjukkan diskusi yang singkat dan efisien.
2. Ketiga metode konstruksi interval kepercayaan (Wald, Wilson, dan Bayesian) menghasilkan hasil yang konsisten dengan rentang $[0,6453; 0,6716]$ untuk merge rate. Konsistensi ini membuktikan robustness estimasi dan keandalan metode yang digunakan.
3. Pengujian hipotesis menggunakan Mann-Whitney U test menghasilkan p-value = $4,03 \times 10^{-26}$, yang jauh di bawah $\alpha = 0,05$, sehingga H_0 ditolak. Terdapat perbedaan yang signifikan secara statistik dalam durasi penyelesaian issue antara 2025 dan 2026, dengan issues tahun 2026 diselesaikan rata-rata 19,3 hari lebih cepat. Effect size Cohen's d = 0,4257 tergolong kecil.
4. Implementasi Bloom Filter menghasilkan FPR empiris 0,65% dibanding FPR teoretis $4,19 \times 10^{-6}$. Perbedaan ini merupakan trade-off yang expected dari implementasi dengan parameter yang belum dioptimalkan, namun tetap mendemonstrasikan efektivitas struktur data probabilistik dalam konteks repository audit.
5. Secara keseluruhan, repository pandas-dev/pandas menunjukkan kondisi yang sehat secara statistik: merge rate tinggi, diskusi efisien, dan tren peningkatan kecepatan penyelesaian issue yang signifikan.

5.2 Saran

Berdasarkan temuan penelitian ini, berikut saran yang dapat disampaikan:

1. Maintainer pandas disarankan mempertahankan merge rate saat ini dengan memperjelas kriteria penerimaan PR dalam template pull request. Checklist yang eksplisit akan membantu kontributor baru melakukan self-evaluation sebelum submit, mengurangi PR yang tidak memenuhi standar.
2. Praktik-praktik yang diterapkan di tahun 2026 yang berkontribusi pada penurunan durasi penyelesaian issue sebaiknya didokumentasikan dalam CONTRIBUTING.md sebagai best practice yang dapat direplikasi ke depannya.
3. Implementasi dashboard monitoring statistik berkala menggunakan GitHub Actions dapat membantu memantau kesehatan repository secara otomatis, menggunakan nilai $\theta = 0,6586$ dan $\lambda = 2,3841$ sebagai baseline KPI.
4. Untuk penelitian selanjutnya, analisis dapat diperluas dengan segmentasi berdasarkan label issue (bug, feature, documentation) dan analisis sentimen komentar untuk pemahaman yang lebih mendalam tentang dinamika komunitas.
5. Parameter Bloom Filter dapat dioptimalkan dengan menyesuaikan ukuran bit array dan jumlah fungsi hash berdasarkan jumlah elemen yang diharapkan untuk mendekati FPR teoretis.

DAFTAR PUSTAKA

GitHub. (2025). GitHub REST API Documentation. Retrieved from <https://docs.github.com/en/rest>

GitHub. (2025). pandas-dev/pandas Repository. Retrieved from <https://github.com/pandas-dev/pandas>

Kalliamvakou, E., Gousios, G., Blincoe, K., Singer, L., German, D. M., & Damian, D. (2016). An in-depth study of the promises and perils of mining GitHub. *Empirical Software Engineering*, 21(5), 2035-2071.

Lenarduzzi, V., Nikkola, V., Saarimäki, N., & Taibi, D. (2021). Does code quality affect pull request acceptance? an empirical study. *Journal of Systems and Software*, 171, 110806.

Zhang, X., Yu, Y., Gousios, G., & Rastogi, A. (2022). Pull request decisions explained: An empirical overview. *IEEE Transactions on Software Engineering*, 49(2), 849-871.

Wessel, M., Vargovich, J., Gerosa, M. A., & Treude, C. (2023). Github actions: the impact on the pull request process. *Empirical Software Engineering*, 28(6), 131.

Adejumo, E. K., & Johnson, B. (2025). An Empirical Validation of Open Source Repository Stability Metrics. *arXiv preprint arXiv:2508.01358*.